

Predicción del Riesgo de Cáncer de Pulmón a través de Aprendizaje Automático basado en Datos de Cuestionarios sobre Estilo de Vida

Samir Chávez Cáceres, Angel Hinchó Jove, Maribel Molina Barriga, Aurea Soriano Vargas

Arequipa, Perú

Universidad Nacional de San Agustín (UNSA)

Universidade Estadual de Campinas (UNICAMP)



Introducción

El cáncer de pulmón, principal causa de mortalidad a nivel global, representa el 22% de las defunciones por neoplasias malignas. Está influenciado por factores genéticos, ambientales y de estilo de vida, lo cual destaca la importancia de la identificación precoz. A pesar de la eficacia de métodos como la tomografía computarizada y la radiografía en etapas avanzadas, la disparidad en la accesibilidad económica y geográfica a estos procedimientos subraya la necesidad de enfoques estratégicos. Presentamos una metodología integral que utiliza aprendizaje automático para predecir el riesgo de cáncer de pulmón a partir de datos de cuestionarios. Esta metodología se distingue por su evaluación comparativa de clasificadores, enfocándose en lograr la máxima sensibilidad y discriminación para la detección temprana y precisa así como en la importancia de la explicabilidad de los resultados y el análisis exhaustivo de características de los conjuntos de datos, abordando limitaciones en estudios anteriores.





Figura 1. Cáncer de Pulmón y Trabajos Relacionados. [11].

Trabajos Relacionados

Estudios utilizan aprendizaje automático para mejorar la detección temprana del cáncer de pulmón. Mamum et al. [7] destacan el rendimiento de XGBoost, Rikta et al. [12] logran resultados superiores con GBM y técnicas de balanceo. Thaventhiran & Sekar [16] proponen un modelo de aprendizaje profundo exitoso. Dritsas et al. [3] encuentran que RotF tiene un alto rendimiento. Patra R. [9] destaca que RBF es eficaz. Viera et al. [17] utilizan ANN con éxito. Aunque estos estudios muestran el potencial del aprendizaje automático, algunos carecen de explicabilidad en sus algoritmos, lo que puede afectar la transparencia y confianza en la tecnología [7], [16]. Se destaca la importancia de proporcionar detalles sobre los conjuntos de datos utilizados [3], [17].

Metodología

Comienza con la preparación de los cuestionarios, luego se realiza un análisis exploratorio para identificar problemas y seleccionar funciones de preprocesamiento que mejoren la calidad de los datos. Se dividen los datos en conjuntos de entrenamiento y prueba mediante el método K-Fold Cross Validation, se procede al entrenamiento de modelos de clasificación binaria. Se incorporan técnicas de explicabilidad para entender cómo los modelos toman decisiones, facilitando la identificación de sesgos. Se evalúa con métricas específicas, como precisión y recall. Con los modelos entrenados, la explicabilidad y las métricas, se realiza la predicción del riesgo de cáncer de pulmón, asegurando conclusiones respaldadas por argumentos sólidos y transparentes para su utilidad clínica.




Figura 2. Metodología Propuesta y Utilizada para la Elaboración de Modelos y su Nivel de Explicabilidad. [Elaboración Propia].

Resultados Esperados

Se espera desarrollar un modelo de clasificación de aprendizaje automático sensible y preciso para predecir el riesgo de cáncer de pulmón a partir de datos de cuestionarios de estilo de vida, superando limitaciones existentes, especialmente en términos de explicabilidad. La comparación entre diversos clasificadores proporcionará información valiosa sobre cuál exhibe la máxima sensibilidad y capacidad de discriminación en individuos con alto riesgo, informando la selección de modelos para aplicaciones clínicas y mejorando la toma de decisiones médicas. Como implementación, la aplicación de técnicas de MLOps se busca desplegar la solución de aprendizaje automático para su disponibilidad en general.




Figura 4. Análisis Exploratorio de Datos y Gráficas. [Elaboración Propia].

Conclusiones y Discusión

Del análisis del dataset se destaca relaciones significativas entre el consumo de alcohol, el hábito de fumar y el cáncer; especialmente en mujeres se resalta la relación de tener un mal estado mental como sentir ansiedad. Se abordará desafíos como el desbalanceamiento, el uso de modelos con optimización de hiper-parámetros y evaluación con métricas clave y explicaciones locales. El enfoque busca mejorar la interpretación de los modelos para la predicción efectiva del cáncer de pulmón.

Reconocimientos

Agradecemos a Maribel Molina Barriga y Aurea Soriano Vargas por ser nuestras asesoras y acompañarnos durante la postulación a CONASEIN.

Referencias

[3] M. Imran, S. Bashir, Z. Sikandar & F. Hassan. An evaluation of machine learning classifiers and ensembles for early stage prediction of lung cancer. In 2018 3rd international conference on emerging trends in engineering, pages 1–4. IEEE, 2018.

[7] E. Nemlander, A. Rosenblad, E. Abedi, S. Ekman, J. Hasselstrom, L. Eriksson and A. Carlsson. Lung cancer prediction using machine learning on data from a symptom e-questionnaire for never smokers, former smokers and current smokers. 2022.

[9] PR Radhika, Rakhi AS Nair and G Veena. A comparative study of lung cancer detection using machine learning algorithms. In 2019 IEEE international conference on electrical, computer and communication technologies (ICECCT), pages 1–4. IEEE, 2019.

[11] S. Tasmin, K. Mohammad, N. Biswas, R. Mostafiz, F. Sharmin, and S. Kumar. Xml-gbm lung: An explainable machine learning-based application for the diagnosis of lung cancer.

[12] A. Shukla, S. Podder, S. R Chaudry, B. S Benn, and J. S Kurman. Non-small cell lung cancer: epidemiology, screening, diagnosis, and treatment. AIMS Medical Science. 2022.

[16] C. Thaventhiran and K. R. Sekar. Target projection feature matching based deep ann with lstm for lung cancer prediction. Intelligent Automation & Soft Computing, 31(1):495–506, 2022.

[17] E. Vieira et al. Data mining approach to classify cases of lung cancer. Trends and Applications in Information Systems and Technologies. 2021.